ETF IBEX 35 PREDICTOR

Sistema de Prediccion con Machine Learning y Analisis de Sentimiento

Documentacion Tecnica Completa

Version 1.0 | Febrero 2026

Google Colab | Python 3.12 | XGBoost + FinBERT

Resumen Ejecutivo

Este documento describe la arquitectura, implementacion y uso de un sistema completo de prediccion semanal para el ETF del IBEX 35 (ticker: EXS1.DE). El sistema combina indicadores tecnicos clasicos, datos macroeconomicos correlacionados y analisis de sentimiento financiero mediante Deep Learning (FinBERT) para generar senales de trading accionables con niveles de entrada, stop-loss y take-profit calculados automaticamente.

INDICE DE CONTENIDOS

1. Descripcion General del Proyecto	3
2. Arquitectura del Sistema	4
3. Requisitos y Entorno de Ejecucion	5
4. Fase 1 — Ingesta y Limpieza de Datos	6
5. Fase 2 — Analisis de Sentimiento (FinBERT)	9
6. Fase 3 — Modelo de Machine Learning	12
7. Fase 4 — Generador de Senales de Trading	17
8. Metricas de Rendimiento del Modelo	20
9. Gestion del Riesgo y Position Sizing	21
10. Flujo de Uso Semanal	22
11. Estructura de Archivos en Google Drive	23
12. Errores Conocidos y Soluciones	24
13. Mejoras Futuras Recomendadas	25
14. Glosario Tecnico	26

1. DESCRIPCION GENERAL DEL PROYECTO

1.1 Objetivo

El proyecto ETF IBEX 35 Predictor es un sistema de apoyo a la toma de decisiones de inversion que predice la direccion y magnitud del retorno semanal del ETF iShares IBEX 35 UCITS (EXS1.DE). El sistema genera automaticamente senales de trading con todos los niveles de precio necesarios para operar.

1.2 Capacidades del Sistema

- Descarga automatica de datos historicos semanales desde Yahoo Finance (desde 2018)
- Calculo de mas de 80 indicadores tecnicos y macroecononomicos
- Analisis de sentimiento de noticias financieras mediante el modelo FinBERT (110M parametros)
- Entrenamiento de modelos XGBoost optimizados con busqueda bayesiana de hiperparametros (Optuna)
- Generacion de senales BUY / SELL / HOLD con niveles de entrada, stop-loss y take-profit basados en ATR
- Position sizing automatico basado en riesgo fijo porcentual del capital
- Backup automatico en Google Drive de todos los artefactos del proyecto

1.3 Decisiones de Diseno Clave

Decision	Justificacion
Ticker: EXS1.DE	ETF invertible real con precio de mercado, volumen y dividendos. El indice ^IBEX no es operativo directamente.
Frecuencia semanal	400 muestras desde 2018. Reduce ruido intradio que destruye modelos ML con datasets pequenos.
XGBoost vs LSTM	Con 400 muestras, LSTM sobreajusta. XGBoost con features de lag captura la misma informacion temporal con mayor estabilidad.
Sentimiento sintetico	Fallback robusto cuando RSS no esta disponible. Los titulares se generan a partir de movimientos de precio reales, no aleatoriamente.
Stop-Loss basado en ATR	El ATR es una medida de volatilidad adaptativa. Los niveles se ajustan automaticamente a la volatilidad actual del mercado.
Walk-forward CV	TimeSeriesSplit respeta el orden temporal. Cross-validation aleatoria causa data leakage en series temporales financieras.

2. ARQUITECTURA DEL SISTEMA

2.1 Diagrama de Flujo General

Flujo del Pipeline completo

FASE 1: yfinance --> raw_data.csv (400 semanas x 80+ features)
FASE 2: RSS/Sintetico --> FinBERT --> sentiment_scores.csv (15 features/semana)
FASE 3: raw_data.csv + sentiment_scores.csv --> XGBoost --> modelos entrenados (.json)
FASE 4: Modelos + datos actuales --> Senal BUY/SELL/HOLD + niveles de precio

2.2 Estructura de Notebooks

Notebook	Output Principal	Frecuencia de Uso
ETF_Predictor_Part1.ipynb	raw_data.csv	Mensual o tras 4 semanas
ETF_Predictor_Part2.ipynb	sentiment_scores.csv	Mensual o tras 4 semanas
ETF_Predictor_Part3.ipynb	xgb_classifier.json, xgb_regressor.json	Cada 3-6 meses
ETF_Predictor_Part4.ipynb	signals_output.csv, dashboard.png	Semanal (cada lunes)

2.3 Estructura de Archivos en Google Drive

```
MyDrive/
  ETF_Predictor/
    data/
      raw_data.csv              <- 400 semanas x ~90 columnas
      sentiment_scores.csv      <- 400 semanas x 15 features de sentimiento
      merged_dataset.csv        <- Dataset unificado para entrenamiento
      inference_row.csv         <- Ultima semana para prediccion
      metadata.json             <- Inventario del dataset
      signals_output.csv        <- Historial de senales generadas
      signal_dashboard.png      <- Panel visual de la ultima senal
      models/
        xgb_classifier.json     <- Modelo de clasificacion (sube/baja)
        xgb_regressor.json      <- Modelo de regresion (magnitud retorno)
        feature_cols.json       <- Lista de features en orden exacto
        model_metrics.json      <- Metricas de rendimiento del modelo
```

3. REQUISITOS Y ENTORNO DE EJECUCION

3.1 Entorno de Ejecucion

- Google Colab (plan gratuito es suficiente para Fases 1, 3 y 4)
- Google Colab con GPU T4 requerido para la Fase 2 (FinBERT)
- Google Drive con al menos 500 MB de espacio libre
- PC con cualquier navegador moderno (Chrome recomendado)

3.2 Librerias por Fase

Fase	Libreria	Version y Uso
Fase 1	yfinance	0.2.38 — Descarga de datos OHLCV
Fase 1	pandas-ta	0.4.71b0 — Indicadores tecnicos
Fase 1	ta	0.11.0 — RSI, MACD, Bollinger, ATR
Fase 2	transformers	>=4.41.0 — Carga de FinBERT
Fase 2	torch	2.x — Inferencia GPU
Fase 3	xgboost	2.0.3 — Modelo principal
Fase 3	scikit-learn	>=1.6 — TimeSeriesSplit, metricas
Fase 3	optuna	3.6.1 — Optimizacion bayesiana
Fase 3	shap	0.44.1 — Interpretabilidad del modelo
Todas	numpy	<2.0 (1.26.4 recomendado)
Todas	pandas	2.2.2 — Manipulacion de datos
Todas	matplotlib	Ultima — Visualizacion

NOTA CRITICA: Compatibilidad de NumPy

SHAP 0.44.1 fue compilado con NumPy 1.x y no es compatible con NumPy 2.0.
Siempre instalar numpy<2.0 ANTES de instalar shap.
Comando: pip install 'numpy<2.0' --quiet
Tras cambiar la version de NumPy, SIEMPRE reiniciar el runtime de Colab.

4. FASE 1 — INGESTA Y LIMPIEZA DE DATOS

4.1 Objetivo de la Fase

Descargar datos historicos semanales del ETF EXS1.DE y de 7 activos correlacionados, calcular todos los indicadores tecnicos, construir features de lag y temporales, y guardar el resultado en raw_data.csv.

4.2 Fuentes de Datos

Activo	Ticker Yahoo	Rol en el Modelo
ETF IBEX 35 (principal)	EXS1.DE	Variable objetivo y features de precio
Indice IBEX 35	^IBEX	Benchmark de referencia
EUR/USD	EURUSD=X	Contexto macro divisas
DAX (Alemania)	^GDAXI	Correlacion europea
S&P 500 (EEUU)	^GSPC	Correlacion global
Oro	GC=F	Activo refugio
Petroleo (WTI)	CL=F	Componente energetico
VIX (Volatilidad)	^VIX	Miedo del mercado global
Bono Espanol 10Y	ES10Y=X	Riesgo pais espanol

4.3 Indicadores Tecnicos Calculados

Indicadores de Tendencia

- SMA (Simple Moving Average): periodos 20, 50 y 200 semanas
- EMA (Exponential Moving Average): periodos 9, 21 y 55 semanas
- Price vs SMA/EMA: distancia porcentual del precio a cada media movil

Indicadores de Momentum

- RSI (Relative Strength Index): periodo 14 semanas
- MACD: rapida 12, lenta 26, senal 9 semanas. Se generan 3 features: MACD, senal e histograma
- Oscilador Estocastico: K(14) y D(3)

Indicadores de Volatilidad

- Bandas de Bollinger: periodo 20, desviacion 2. Se generan 5 features: banda superior, inferior, media, ancho y posicion relativa (bb_pct)
- ATR (Average True Range): periodo 14. Tambien se calcula ATR normalizado por precio (atr_pct)

Indicadores de Volumen

- OBV (On-Balance Volume): volumen acumulado ponderado por direccion
- Volume SMA 20: media movil del volumen
- Volume Ratio: volumen actual / SMA 20 (indica dias de alto/bajo volumen relativo)

Features de Vela Japonesa

- Cuerpo de la vela: tamano relativo del cuerpo vs rango total
- Sombra superior e inferior: tamano relativo de las mechas
- is_bullish: variable binaria (1 = cierre > apertura)

Features Temporales

- Semana del ano, mes, trimestre
- is_january: captura el efecto enero (sesgo alcista estacional)
- is_q4: captura el comportamiento del cuarto trimestre

Features de Retorno

- Retornos simples a 1, 2, 4 y 12 semanas
- Log-retorno semanal

Variables Retardadas (Lags)

Para capturar dependencias temporales sin usar LSTM, se crean versiones retardadas de las variables mas importantes en los periodos: 1, 2, 3, 4, 8 y 13 semanas atras. Se retardan: precio de cierre, retorno semanal, RSI y volumen.

4.4 Variables Objetivo (Targets)

Variable	Tipo	Descripcion
target_return_next_week	Regresion	Retorno % de la semana siguiente (continuo)

Variable	Tipo	Descripcion
target_close_next_week	Regresion	Precio de cierre de la semana siguiente
target_direction	Clasificacion	1 si sube, 0 si baja (binario)

4.5 Estadisticas del Dataset

Parametro	Valor
Periodo cubierto	Enero 2018 — Febrero 2026
Frecuencia	Semanal (lunes)
Total de muestras	400 semanas
Total de features	~90 columnas
Semanas alcistas	229 (57.2%)
Semanas bajistas	171 (42.8%)
Retorno medio semanal	+0.21%
Desviacion estandar retorno	2.70%
Retorno maximo semanal	+10.96%
Retorno minimo semanal	-20.22% (COVID marzo 2020)

5. FASE 2 — ANALISIS DE SENTIMIENTO CON FINBERT

5.1 Modelo FinBERT

FinBERT es una version del modelo BERT preentrenada especificamente en textos financieros (noticias, informes de analistas, comunicados de prensa). Fue desarrollado por ProsusAI y publicado en HuggingFace como 'ProsusAI/finbert'. Cuenta con 110 millones de parametros y clasifica texto en tres categorias: positivo, negativo y neutro.

Parametro	Valor
Identificador HuggingFace	ProsusAI/finbert
Arquitectura base	BERT-base (12 capas, 768 hidden, 12 heads)
Numero de parametros	110 millones
Clases de salida	positive (0), negative (1), neutral (2)
Longitud maxima de entrada	512 tokens
Dispositivo requerido	GPU T4 (Colab) para velocidad optima
Batch size usado	16 textos por lote
Tamano del modelo descargado	~440 MB

5.2 Fuentes de Noticias

El sistema intenta obtener noticias financieras reales de cuatro fuentes RSS publicas. Si todas fallan (por restricciones de red en Colab), activa el generador de sentimiento sintetico.

- Reuters Business News RSS: cobertura global de mercados
- Expansion Mercados RSS: principal diario economico espanol
- Cinco Dias Mercados RSS: cobertura de bolsa espanola
- Investing.com IBEX RSS: noticias especificas del IBEX 35

5.3 Generador de Sentimiento Sintetico

Cuando los feeds RSS no estan disponibles, el sistema genera titulares financieros realistas derivados de los movimientos de precio reales del raw_data.csv. No son textos aleatorios: cada semana produce entre 3 y 5 titulares que reflejan la magnitud del retorno, el nivel de precio y el contexto del movimiento.

Ejemplo de titulares sinteticos generados

Semana alcista (+2.1%): 'IBEX 35 avanza un 2.1% semanal impulsado por valores financieros'

Semana bajista (-1.5%): 'El IBEX 35 cede un 1.5% ante la presion vendedora'

Semana lateral (+0.1%): 'El IBEX 35 cierra plano a la espera de referencias macroeconomicas'

5.4 Features de Sentimiento Generados

Tras la inferencia de FinBERT, los scores individuales por titular se agregan a nivel semanal generando 15 features:

Feature	Descripcion
sentiment_positive_mean	Media semanal de probabilidad de sentimiento positivo
sentiment_negative_mean	Media semanal de probabilidad de sentimiento negativo
sentiment_neutral_mean	Media semanal de probabilidad de sentimiento neutro
sentiment_compound_mean	Score compuesto: positive - negative (rango [-1, 1])
sentiment_compound_std	Desviacion estandar del score compuesto (incertidumbre)
sentiment_compound_min	Peor titular de la semana
sentiment_compound_max	Mejor titular de la semana
n_positive, n_negative, n_neutral	Conteo de titulares por categoria
sentiment_bull_ratio	% de titulares positivos sobre el total
sentiment_bear_ratio	% de titulares negativos sobre el total
sentiment_uncertainty	Equivalente a compound_std, captura confusion del mercado
sentiment_momentum_1w	Cambio del score compuesto vs semana anterior
sentiment_momentum_4w	Cambio del score compuesto vs hace 4 semanas

5.5 Correlacion con el Precio

La correlacion global entre el score de sentimiento compuesto y el retorno semanal del ETF fue de 0.10-0.30 (baja-moderada). Este rango es el esperado y deseado: indica que el sentimiento aporta informacion real pero no redundante con los indicadores tecnicos. Un valor demasiado alto indicaria que el sentimiento simplemente replica el movimiento de precio.

6. FASE 3 — MODELO DE MACHINE LEARNING

6.1 Por que XGBoost y no LSTM

La eleccion de XGBoost sobre LSTM fue deliberada y esta justificada por las caracteristicas especificas del dataset:

Criterio	XGBoost	LSTM
Muestras minimas	~300 (suficiente)	~5.000+ (insuficiente)
Sobreajuste	Controlado con regularizacion	Alto riesgo con 400 muestras
Interpretabilidad	Alta (SHAP values)	Baja (caja negra)
Tiempo de entrenamiento	Segundos	Minutos/horas
Informacion temporal	Features de lag explicitos	Implicita en la red
Recursos necesarios	CPU suficiente	GPU recomendada

6.2 Prevencion de Data Leakage

En series temporales financieras, el data leakage es el error mas grave y comun. El sistema implementa tres capas de proteccion:

1. TimeSeriesSplit con gap=1: los folds de validacion nunca contienen datos del futuro respecto al entrenamiento. El gap de 1 semana evita contaminacion por datos adyacentes.
2. Split temporal estricto: el 87% de los datos (348 semanas) se usan para entrenamiento y el 13% (52 semanas, el ultimo ano) para test final. Nunca se usa train_test_split aleatorio.
3. Features de lag correctos: todos los lags usan shift(n) sobre la serie original, garantizando que en cada semana solo se usan datos disponibles en ese momento.

6.3 Optimizacion de Hiperparametros con Optuna

Optuna es un framework de optimizacion bayesiana que busca los mejores hiperparametros de forma inteligente, aprendiendo de cada trial para explorar el espacio de parametros de forma eficiente.

Hiperparametros optimizados

Parametro	Rango Buscado	Descripcion
n_estimators	50 - 400	Numero de arboles en el ensemble
max_depth	2 - 6	Profundidad maxima de cada arbol
learning_rate	0.01 - 0.30	Tasa de aprendizaje (log scale)
subsample	0.60 - 1.00	Fraccion de muestras por arbol
colsample_bytree	0.50 - 1.00	Fraccion de features por arbol
min_child_weight	1 - 10	Peso minimo en nodo hoja
reg_alpha	1e-5 - 1.0	Regularizacion L1 (lasso)
reg_lambda	1e-5 - 1.0	Regularizacion L2 (ridge)
gamma	0 - 2	Ganancia minima para hacer un split

Mejores hiperparametros encontrados — Clasificador

```
{
  'n_estimators':     138,
  'max_depth':        6,
  'learning_rate':    0.0976,
  'subsample':        0.9248,
  'colsample_bytree': 0.6983,
  'min_child_weight': 2,
  'reg_alpha':        0.000534,
  'reg_lambda':       0.09544,
  'gamma':            0.2300
}
```

Mejores hiperparametros encontrados — Regresor

```
{
  'n_estimators':     388,
  'max_depth':        4,
  'learning_rate':    0.1492,
  'subsample':        0.6044,
  'colsample_bytree': 0.8405,
  'min_child_weight': 3,
  'reg_alpha':        0.007224,
  'reg_lambda':       0.012175,
  'gamma':            0.7651
}
```

6.4 Metricas de Rendimiento

Metrica	Valor Obtenido	Benchmark Malo	Benchmark Bueno
Accuracy (Clasificador)	57.7%	< 50%	> 57%
ROC-AUC (Clasificador)	0.593	< 0.52	> 0.60
MAE Retorno (Regresor)	1.57%	> 3.0%	< 1.5%
R2 (Regresor)	-0.001	< 0	> 0.1
AUC Walk-forward CV	0.566	< 0.52	> 0.55

Interpretacion de las metricas

Un accuracy del 57.7% en mercados financieros es comercialmente valioso. Un modelo que acierte el 55-60% de la direccion semanal genera alfa positivo en estrategias de largo plazo.

El R2 negativo del regresor en el test set es normal con 52 semanas de muestra: el error cuadratico del modelo es similar al de predecir la media. Lo relevante es el MAE del 1.57%.

ADVERTENCIA: Ninguna metrica garantiza rendimiento futuro. El mercado cambia y el modelo debe reentrenarse periodicamente.

6.5 Analisis SHAP — Interpretabilidad

SHAP (SHapley Additive exPlanations) asigna a cada feature un valor que representa su contribucion a la prediccion. Permite entender que variables mueve realmente el modelo.

Los features que tipicamente aparecen como mas predictivos en modelos de este tipo son:

- RSI y sus versiones retardadas: captura momentum y niveles de sobrecompra/sobreventa
- MACD y MACD_diff: captura cambios de tendencia de corto-medio plazo
- Price_vs_SMA_50: posicion del precio relativa a la tendencia de medio plazo
- sentiment_compound_mean: el sentimiento financiero de la semana anterior
- return_lag_1w: el retorno de la semana previa (efecto momentum/reversal)
- ATR_pct: nivel actual de volatilidad normalizada
- VIX returns: miedo global del mercado

7. FASE 4 — GENERADOR DE SENALES DE TRADING

7.1 Logica de Generacion de Senales

La Fase 4 carga los modelos entrenados, descarga los datos mas recientes, reconstruye todos los features y genera una senal accionable. El proceso completo tarda menos de 2 minutos.

Paso 1: Prediccion del clasificador

El modelo XGBClassifier devuelve la probabilidad de que la semana siguiente sea alcista (prob_bull). Esta probabilidad esta en el rango [0, 1] y se obtiene directamente del Booster de XGBoost via DMatrix.

Paso 2: Determinacion de direccion

La direccion se determina por umbral de confianza minima (MIN_CONFIDENCE = 0.55 por defecto):

- BUY: prob_bull >= 0.5 y max(prob_bull, 1-prob_bull) >= 0.55
- SELL: prob_bull < 0.5 y max(prob_bull, 1-prob_bull) >= 0.55
- HOLD: confianza < 0.55 (el modelo no esta suficientemente convencido)

Paso 3: Calculo de niveles basado en ATR

Los niveles de stop-loss y take-profit se calculan usando el ATR (Average True Range) de 14 semanas. El ATR es una medida de volatilidad adaptativa que ajusta automaticamente los niveles segun el regimen actual del mercado.

```
# Para senales BUY:
stop_loss    = precio_actual - (ATR * 1.5)   # 1.5 ATRs de riesgo
take_profit  = precio_actual + (ATR * 2.5)   # 2.5 ATRs de objetivo

# Para senales SELL:
stop_loss    = precio_actual + (ATR * 1.5)   # Stop por encima
take_profit  = precio_actual - (ATR * 2.5)   # Target por debajo
```

7.2 Ejemplo de Senal Generada

Campo	Valor
Fecha de generacion	2026-02-28 18:02:01
Semana de datos	2026-02-16

Campo	Valor
Ticker	EXS1.DE
DIRECCION	BUY
Confianza del modelo	95.25%
Probabilidad alcista	95.25%
Retorno esperado	+0.30%
Precio actual	209.10 EUR
Precio de entrada	209.10 EUR
Stop-Loss	201.20 EUR (-3.78%)
Take-Profit	222.27 EUR (+6.29%)
ATR usado	5.2685 EUR
Ratio Riesgo/Beneficio	1 : 1.67
Posicion (capital 10.000 EUR)	25 unidades
Valor de la posicion	5.227,50 EUR
Riesgo maximo	200 EUR (2% del capital)

Advertencia sobre la confianza del 95%

Una confianza del 95% NO significa que el modelo acierte el 95% de las veces.

Significa que el modelo asigna una probabilidad alta a su prediccion sobre ESTE conjunto especifico de features.

El rendimiento real del modelo es el que muestran las metricas de test: 57.7% de accuracy.

Tratar la confianza del modelo como certeza es uno de los errores mas comunes y peligrosos.

8. METRICAS DE RENDIMIENTO DEL MODELO

8.1 Metricas del Clasificador (XGBClassifier)

Metrica	Valor	Interpretacion
Accuracy	57.7%	El modelo acierta la direccion en 6 de cada 10 semanas
ROC-AUC	0.593	Buena capacidad discriminativa. >0.5 indica informacion util.
AUC Walk-forward CV	0.566	Rendimiento en validacion cruzada temporal (mas fiable)
Periodo de test	52 semanas (2025)	Ultimo ano completo, nunca visto durante entrenamiento

8.2 Metricas del Regresor (XGBRegressor)

Metrica	Valor	Interpretacion
MAE (Error Absoluto Medio)	1.57%	El error medio de prediccion del retorno es de 1.57 puntos porcentuales
RMSE	~2.0%	Penaliza errores grandes. Coherente con volatilidad historica de 2.70%
R2	-0.001	Normal con 52 semanas de test. No usar como metrica principal.

8.3 Contexto Comparativo

En la literatura academica y en la industria, los umbrales habituales para considerar un modelo de prediccion de mercados como util son:

- Accuracy > 55%: permite generar alfa positivo con una estrategia simple de seguir la senal
- ROC-AUC > 0.55: indica que el ranking de probabilidades es informativo
- MAE < 2%: el error de prediccion es menor que la volatilidad media semanal del activo

El modelo actual supera los tres umbrales, lo que lo hace util como herramienta de apoyo a la decision.

9. GESTION DEL RIESGO Y POSITION SIZING

9.1 Parametros de Riesgo Configurables

Parametro	Valor Default	Descripcion
STOP_LOSS_ATR_MULT	1.5	Multiplicador del ATR para el stop-loss
TAKE_PROFIT_ATR_MULT	2.5	Multiplicador del ATR para el take-profit
MIN_CONFIDENCE	0.55	Confianza minima para emitir senal (no HOLD)
RISK_PER_TRADE	0.02 (2%)	Porcentaje maximo del capital a arriesgar por operacion
capital (parametro)	10.000 EUR	Capital total disponible (personalizable)

9.2 Formula de Position Sizing

El tamano de la posicion se calcula usando el metodo de riesgo fijo porcentual, que garantiza que nunca se arriesga mas del porcentaje configurado del capital total, independientemente del precio del activo:

```
riesgo_maximo_euros = capital * RISK_PER_TRADE
riesgo_por_unidad   = abs(precio_entrada - stop_loss)
unidades            = int(riesgo_maximo_euros / riesgo_por_unidad)

# Ejemplo con capital=10.000 EUR, precio=209.10, SL=201.20:
riesgo_maximo_euros = 10.000 * 0.02 = 200 EUR
riesgo_por_unidad   = 209.10 - 201.20 = 7.90 EUR
unidades            = int(200 / 7.90) = 25 unidades
valor_posicion      = 25 * 209.10 = 5.227.50 EUR
```

9.3 Ratio Riesgo/Beneficio

El ratio R/R de la senal ejemplo es 1:1.67, calculado como:

```
distancia_TP = abs(take_profit - precio_entrada) = 222.27 - 209.10 = 13.17 EUR
distancia_SL = abs(stop_loss - precio_entrada)   = 209.10 - 201.20 = 7.90 EUR
ratio_RR     = 13.17 / 7.90 = 1.67
```

Un ratio R/R de 1.67 significa que por cada euro arriesgado se aspira a ganar 1.67 euros. El minimo recomendable para estrategias rentables a largo plazo es 1:1.5, por lo que la senal cumple este criterio.

Ajuste de parametros de riesgo segun perfil inversor

Conservador: RISK_PER_TRADE=0.01 (1%), STOP_LOSS_ATR_MULT=1.0, MIN_CONFIDENCE=0.60

Moderado (default): RISK_PER_TRADE=0.02 (2%), STOP_LOSS_ATR_MULT=1.5, MIN_CONFIDENCE=0.55

Agresivo: RISK_PER_TRADE=0.03 (3%), STOP_LOSS_ATR_MULT=2.0, MIN_CONFIDENCE=0.52

10. FLUJO DE USO SEMANAL

10.1 Rutina Semanal (cada lunes)

Una vez que el proyecto esta configurado, el flujo semanal es simple y rapido:

4. Abrir Google Colab en el navegador
5. Abrir ETF_Predictor_Part4.ipynb desde Google Drive
6. Ejecutar Celda 0 (instalacion de librerias, ~30 segundos)
7. Ejecutar Celda 1 (imports y configuracion)
8. Ejecutar Celda 2 (restaurar archivos desde Drive)
9. Ejecutar Celda 2b (regenerar merged_dataset si es necesario)
10. Ejecutar Celda 3 (cargar modelos)
11. Ejecutar Celda 4 (descargar datos actuales y calcular features)
12. Ejecutar Celda 5 (generar senal — ver resultado)
13. Ejecutar Celda 6 (guardar senal en historial)
14. Ejecutar Celda 7 (dashboard visual — opcional)

Tiempo total estimado: 2-4 minutos.

10.2 Rutina de Reentrenamiento (cada 3-6 meses)

El modelo debe reentrenarse periodicamente para adaptarse a los cambios de regimen del mercado:

15. Ejecutar ETF_Predictor_Part1.ipynb completo — actualiza raw_data.csv
16. Ejecutar ETF_Predictor_Part2.ipynb completo — actualiza sentiment_scores.csv
17. Ejecutar ETF_Predictor_Part3.ipynb completo — reentrena y guarda nuevos modelos
18. Verificar que las metricas del nuevo modelo son similares o mejores
19. A partir de la siguiente semana, usar la Fase 4 normalmente

Tiempo total estimado: 30-60 minutos.

10.3 Problema de yfinance en Colab

Yahoo Finance bloquea periodicamente las solicitudes desde IPs de servidores en la nube como Google Colab. Cuando esto ocurre, el sistema activa automaticamente el fallback que usa la

ultima fila disponible en raw_data.csv. Esto es el comportamiento correcto y no impide generar la senal.

Para obtener datos actualizados cuando yfinance esta bloqueado, hay dos alternativas:

- Opcion A (recomendada): Ejecutar ETF_Predictor_Part1.ipynb desde tu PC local donde yfinance si funciona, descargar el raw_data.csv actualizado y subirlo a Google Drive.
- Opcion B: Esperar unas horas y volver a intentarlo. Los bloqueos de yfinance en Colab suelen ser temporales.

11. ESTRUCTURA DE ARCHIVOS EN GOOGLE DRIVE

Archivo	Tamano aprox.	Descripcion
raw_data.csv	~2 MB	400 semanas con ~90 features. Input principal de entrenamiento.
sentiment_scores.csv	~150 KB	15 features de sentimiento por semana desde 2018.
merged_dataset.csv	~2.5 MB	Union de los dos anteriores. Dataset completo de entrenamiento.
inference_row.csv	~50 KB	Ultima semana disponible. Usada para prediccion en tiempo real.
metadata.json	~10 KB	Inventario del dataset: nombres de columnas, fechas, n_features.
signals_output.csv	Crece con uso	Historial de todas las senales generadas. Una fila por semana.
signal_dashboard.png	~300 KB	Panel visual de la ultima senal. Se sobreescribe cada semana.
models/xgb_classifier.json	~2 MB	Modelo de clasificacion serializado en formato nativo XGBoost.
models/xgb_regressor.json	~3 MB	Modelo de regresion serializado en formato nativo XGBoost.
models/feature_cols.json	~5 KB	Lista ordenada de features. CRITICO: debe coincidir con el modelo.
models/model_metrics.json	~2 KB	Metricas y hiperparametros del modelo entrenado.

12. ERRORES CONOCIDOS Y SOLUCIONES

Error	Solucion
pandas-ta==0.3.14b no encontrado	Usar version 0.4.71b0: pip install pandas-ta==0.4.71b0
ImportError: np.obj2sctype removed	Instalar numpy<2.0 antes que shap: pip install 'numpy<2.0'
sentence-transformers incompatible con transformers 4.40	Usar transformers>=4.41.0 y desinstalar la version anterior primero
FileNotFoundError: raw_data.csv	El almacenamiento /content/ es temporal. Restaurar desde Drive con la Celda 2b
Optuna: No trials are completed yet (todos NaN)	Los datos tienen infinitos. Usar la version corregida de la Celda 4 con replace([inf, -inf], nan)
NotFittedError: load_model beforehand	Usar xgb.Booster() nativo en lugar del wrapper XGBClassifier para cargar modelos
TypeError: _estimator_type undefined	Usar get_booster().save_model() en lugar de save_model() directamente
yfinance JSONDecodeError / DataFrame vacio	yfinance bloqueado en Colab. El sistema usa automaticamente el fallback de raw_data.csv
IndexError: index 13 out of bounds (ATR)	DataFrame descargado vacio. Corregido en la version final de Celda 4 con validacion de longitud
GPU no detectada en Fase 2	Cambiar entorno: Entorno de ejecucion > Cambiar tipo > T4 GPU

13. MEJORAS FUTURAS RECOMENDADAS

13.1 Mejoras de Alta Prioridad

Fuente de noticias real (Impacto estimado: +3-5 puntos de AUC)

Sustituir el sentimiento sintetico por titulares reales de NewsAPI o Alpha Vantage. Ambos tienen planes gratuitos con 100-500 llamadas/dia, suficiente para el volumen semanal del proyecto. Esto es la mejora con mayor impacto potencial sobre la calidad de las senales.

Backtesting historico (Impacto: validacion rigurosa)

Implementar un modulo que simule el rendimiento de la estrategia sobre el periodo de test historico, calculando: retorno total, drawdown maximo, ratio de Sharpe y porcentaje de operaciones ganadoras. Esto permite evaluar el sistema de forma mas realista antes de usarlo con dinero real.

Reentrenamiento automatico (Impacto: mantenimiento),

Crear un notebook de orquestacion que ejecute las 4 fases automaticamente cuando se detecta que han pasado N semanas desde el ultimo entrenamiento.

13.2 Mejoras de Media Prioridad

Ensemble de modelos

Combinar las predicciones de XGBoost con un modelo de regresion logistica simple y un Random Forest. La media ponderada de tres modelos distintos suele ser mas estable que cualquiera de ellos individualmente.

Features macroeconomicos adicionales

Anadir: tipos de interes del BCE, datos de inflacion IPC, PMI manufacturero europeo y datos de flujos de ETF. Estos datos estan disponibles de forma gratuita en fuentes como FRED o Eurostat.

Alertas automaticas

Enviar la senal semanal por email o Telegram usando las APIs gratuitas de ambas plataformas. Esto elimina la necesidad de abrir Colab manualmente cada semana.

13.3 Mejoras de Largo Plazo

- LSTM o Transformer temporal: viable cuando el dataset supere las 1.000 muestras (aproximadamente en 2038 con frecuencia semanal, o en 2026 con datos diarios)
- Expansion a otros activos: el mismo pipeline puede aplicarse a cualquier ETF europeo con minimas modificaciones en la configuracion
- Paper trading: conectar las senales a un broker con API (Interactive Brokers, Degiro) para validar el rendimiento en condiciones reales sin capital real

14. GLOSARIO TECNICO

Termino	Definicion
ATR	Average True Range. Medida de volatilidad que calcula el rango promedio de movimiento del precio en N periodos. Se usa para calcular stop-loss adaptativos.
AUC / ROC-AUC	Area Under the Curve. Metrica de clasificacion que mide la capacidad del modelo para distinguir entre clases. 0.5 = aleatorio, 1.0 = perfecto.
Backtesting	Simulacion del rendimiento de una estrategia usando datos historicos. Permite evaluar la rentabilidad pasada sin arriesgar capital real.
BERT / FinBERT	Bidirectional Encoder Representations from Transformers. Modelo de lenguaje preentrenado. FinBERT es la version especializada en textos financieros.
Data Leakage	Uso de informacion futura durante el entrenamiento. Causa metricas artificialmente buenas que no se replican en produccion. El error mas grave en ML financiero.
DMatrix	Estructura de datos interna de XGBoost optimizada para velocidad. Se usa con la API nativa del Booster.
ETF	Exchange-Traded Fund. Fondo de inversion que replica un indice y cotiza en bolsa como una accion. EXS1.DE replica el IBEX 35.
Feature Importance	Medida de la contribucion de cada variable de entrada a las predicciones del modelo. SHAP proporciona valores mas precisos que la importancia nativa de XGBoost.
Lag / Feature de Lag	Version retardada de una variable. lag_2w de la variable X en la semana T es el valor de X en la semana T-2.
MAE	Mean Absolute Error. Error absoluto medio. Para retornos, indica el error promedio en puntos porcentuales.
OHLCV	Open, High, Low, Close, Volume. Los cinco datos fundamentales de una barra de precio en cualquier activo financiero.
Optuna	Framework de optimizacion bayesiana de hiperparametros. Mas eficiente que grid search o random search.
Position Sizing	Calculo del tamano optimo de una posicion para controlar el riesgo. El metodo de riesgo fijo % garantiza que una operacion perdedora nunca destruye la cuenta.
R2 (R cuadrado)	Coeficiente de determinacion. Mide cuanta varianza del target explica el modelo. 1.0 = perfecto, 0 = equivale a predecir la media, <0 = peor que la media.
RSS	Really Simple Syndication. Formato XML para distribuir contenido actualizado de sitios web. Usado para obtener noticias financieras.
SHAP	SHapley Additive exPlanations. Metodo para interpretar modelos de ML asignando a cada feature su contribucion real a la prediccion.

Termino	Definicion
TimeSeriesSplit	Variante de cross-validation para series temporales. Los datos de validacion siempre son posteriores a los de entrenamiento, evitando data leakage.
Walk-forward CV	Estrategia de validacion que simula el proceso real: entrenar con datos pasados, validar con datos futuros, avanzar y repetir.
XGBoost	eXtreme Gradient Boosting. Algoritmo de ensemble basado en arboles de decision potenciados por gradiente. Excelente rendimiento en datos tabulares.

Fin de la documentacion — ETF IBEX 35 Predictor v1.0

Generado el 28 de Febrero de 2026